Optymalizacja zarządzania indeksami materiałowymi z bazami wektorowymi

Wdrożenie systemu IndeksyGSR opartego na architekturze Qdrant i modelu BGE-M3

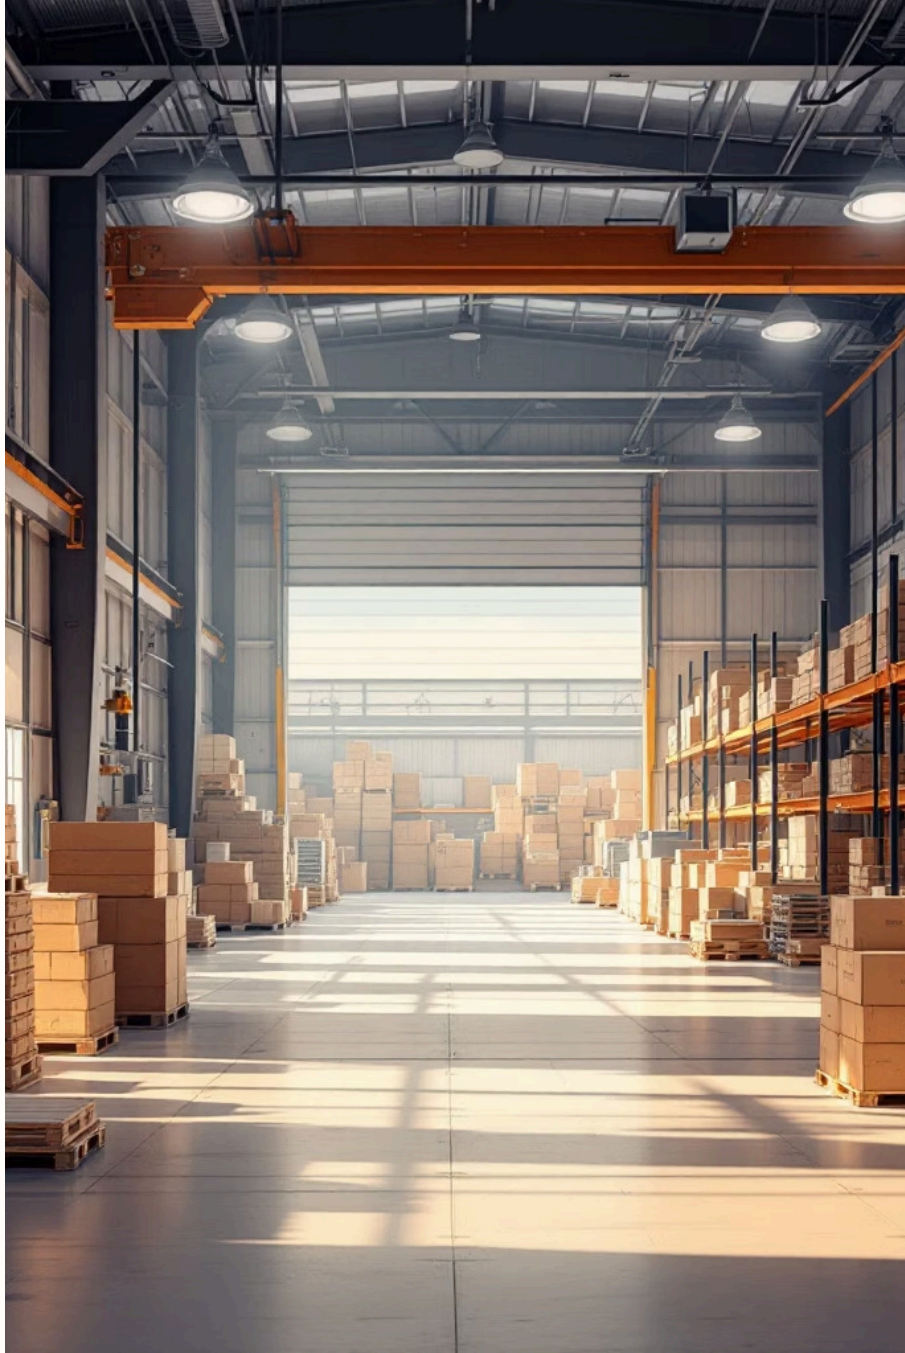

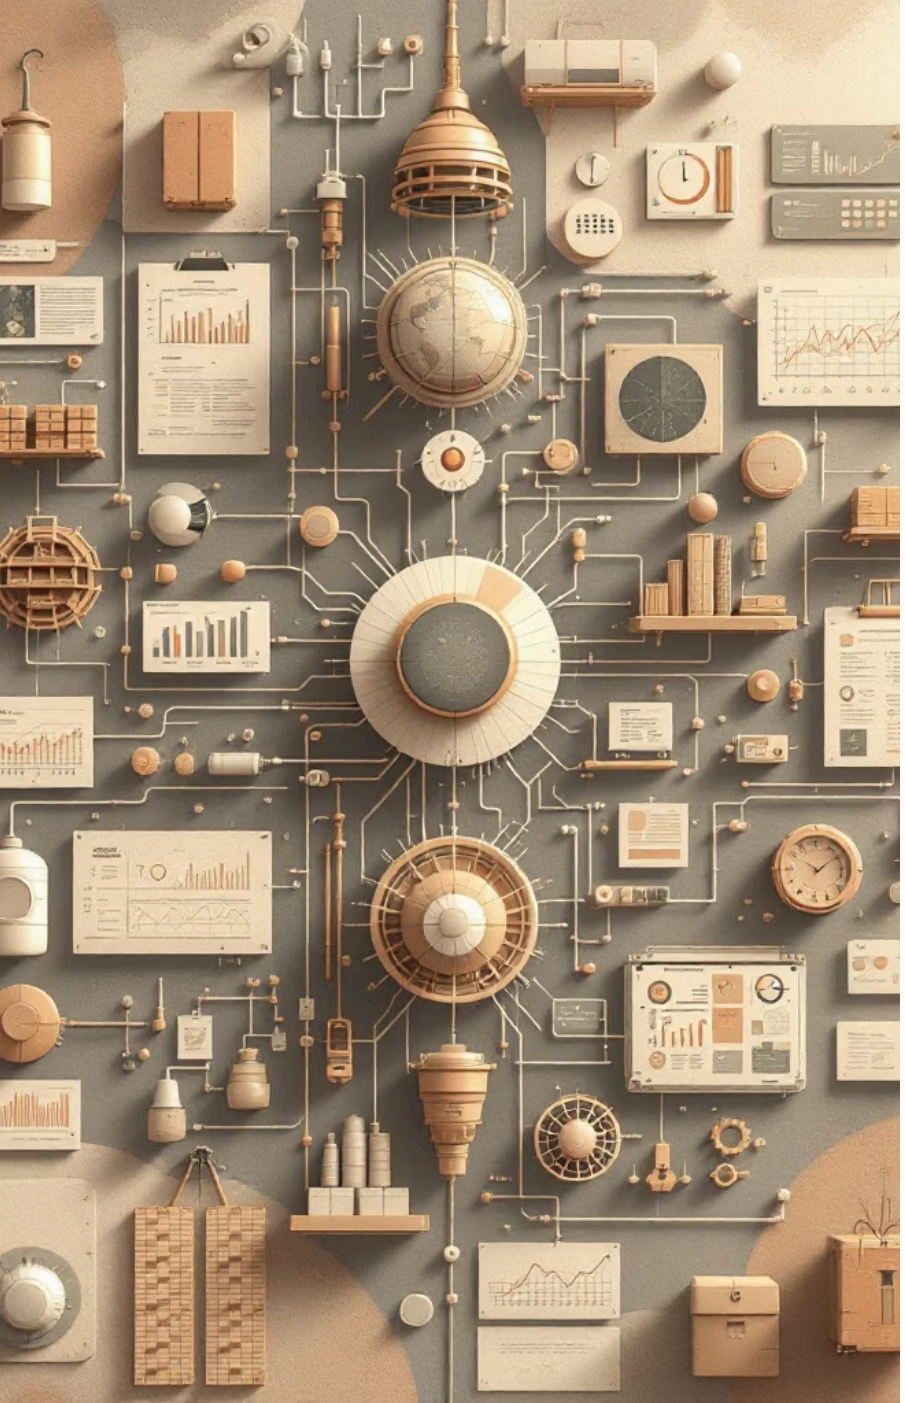

Problem złożonych struktur indeksowania

Kontekst operacyjny

W dużych organizacjach produkcyjnych i logistycznych, zarządzanie złożonymi strukturami indeksowania stanowi kluczowe wyzwanie w utrzymaniu spójności danych operacyjnych. Analizowana organizacja operuje na siedmiosegmentowej strukturze indeksu, obejmującej: Typ, Grupę, Podgrupę, Cechę, Materiał, Odbiór oraz Numer kolejny.

Taka granulacja, choć teoretycznie pozwalająca na precyzyjną identyfikację zasobów, w praktyce staje się źródłem redundancji i błędów wynikających z czynnika ludzkiego. Proces wprowadzania danych jest podatny na nieścisłości terminologiczne, co prowadzi do powstawania duplikatów i paraliżuje efektywność łańcucha dostaw.

Skala problemu

~69 000 zindeksowanych materiałów w organizacji, wymagających ciągłej aktualizacji i utrzymania spójności nomenklatury

Architektura systemu IndeksyGSR

System IndeksyGSR został zaprojektowany, aby usprawnić proces indeksowania materiałów, minimalizując błędy i redundancję. Oto jego kluczowe komponenty i przepływ pracy:

Głównym elementem jest baza wektorowa, która przechowuje zarówno wektory główne, jak i pomocnicze, wzbogacając opis materiału o dane pozyskane przez scraper.

Zapytania użytkowników

Użytkownik wprowadza zapytanie tekstowe lub URL produktu

Decyzja: Zawiera URL?

Jeśli TAK → przekazanie do Scrapera; jeśli NIE → bezpośrednio do bazy wektorowej

Scraper

Pobiera dane ze strony produktu (zapytanie użytkownika + dane ze strony)

Baza wektorowa (Qdrant)

Przechowuje trzy wektory dla każdego indeksu: Wektor gęsty (Dense), Wektor rzadki (Sparse), Wektor pomocniczy (Auxiliary) oraz Metadane (Payload)

Wyszukiwanie → Indeks

Zwraca indeks i nazwę indeksu; wynik skutecznego wyszukania zasila rozbudowany opis materiału

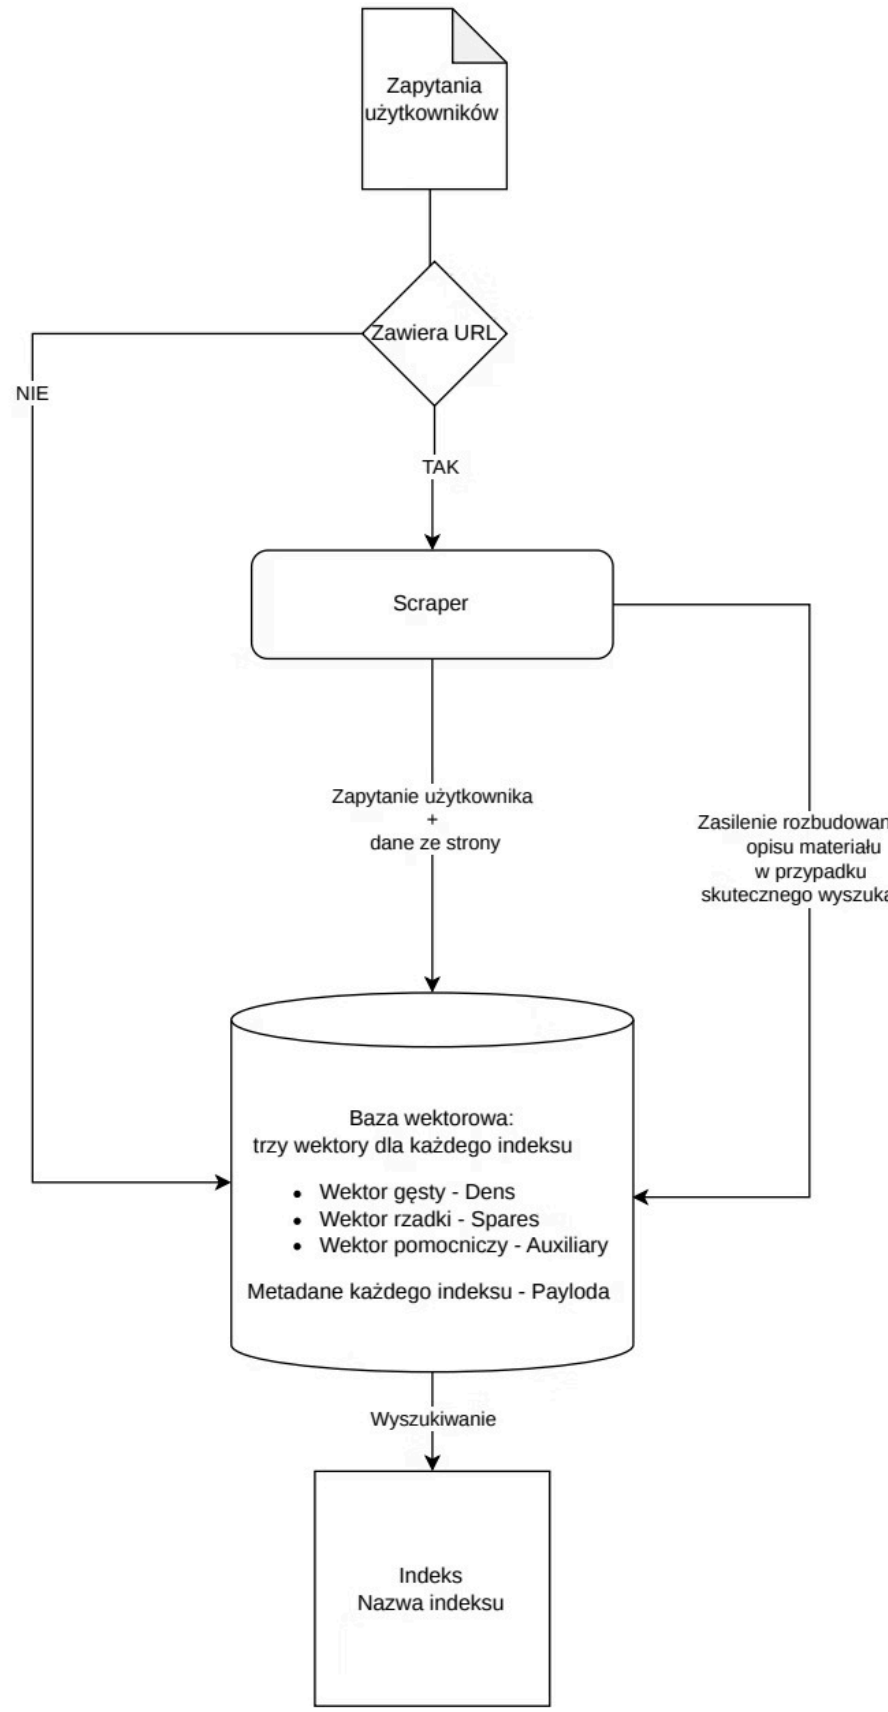

Architektura systemu IndeksyGSR

System został zaprojektowany jako kompleksowe rozwiązanie typu pipeline, integrujące rozproszone źródła danych od lokalnych plików po zasoby chmurowe i serwisy e-commerce.

Backend core

Logika wyszukiwania i sugestii, hybrydowe wyszukiwanie semantyczne z Reciprocal Rank Fusion (RRF), automatyczne sugestie dla nowych indeksów

Pipeline przetwarzania

Parsowanie wiadomości e-mail (.pst), asynchroniczny scraping danych z serwisów Allegro, TME, TIM

Warstwa usług

Komunikacja z bazami Firestore i Qdrant Cloud, embed-server oparty na FastAPI

Model BGE-M3: trzy typy reprezentacji

Wybór modelu BAAI/bge-m3 jako silnika wektoryzacji jest podyktowany jego unikalną zdolnością do obsługi trzech typów reprezentacji w jednym przebiegu, co jest niezwykle istotne w kontekście technicznych indeksów materiałowych.

Wektory gęste (Dense)

1024-wymiarowe reprezentacje uchwytyujące głębokie znaczenie zapytania. System rozumie, że "inox" jest semantycznie tożsamy z "A2" lub "stal nierdzewna", nawet jeśli te słowa nie występują bezpośrednio.

Wektory rzadkie (Sparse)

Oparte na wagach SPLADE, realizują wyszukiwanie leksykalne, skuteczne przy dopasowywaniu specyficznych kodów technicznych jak "M20" czy "DIN 933".

Wektory pomocnicze (Auxiliary)

1024-wymiarowe, dedykowane wyszukiwaniu po surowej nazwie indeksu, umożliwiające szybkie dopasowanie identyfikatorów i nazw własnych.

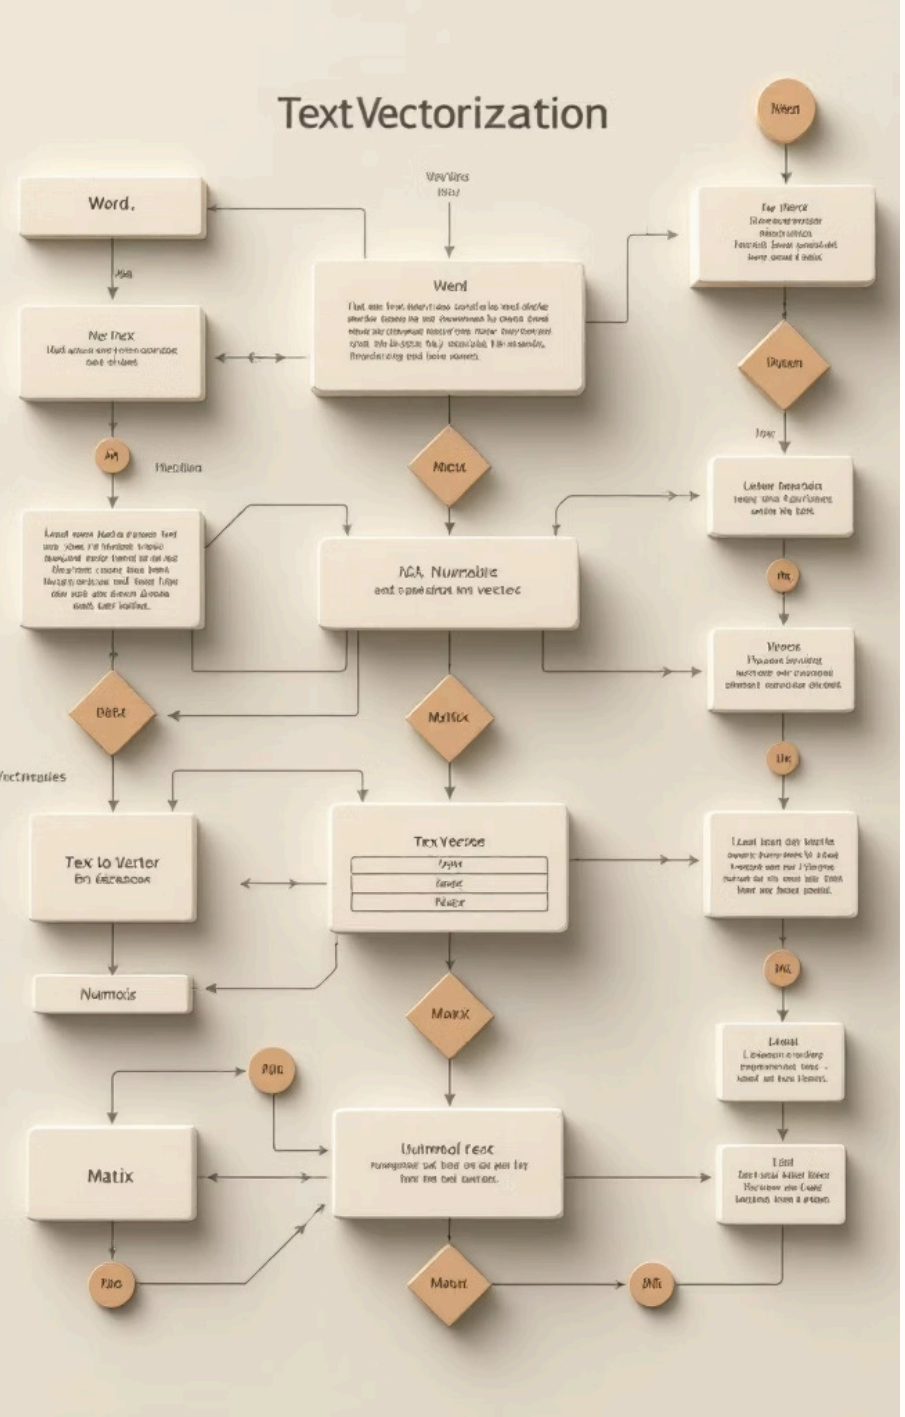

Proces wektoryzacji danych

Trzywarstwowa transformacja tekstu

Proces budowania tekstu do wektoryzacji jest wielowarstwowy i obejmuje:

1. Trzy poziomy segmentów asortymentowych (Typ, Grupa, Podgrupa)
2. Pełną nazwę indeksu
3. Dane uzupełniające: tytuły i specyfikacje techniczne pozyskane drogą scrapingu

Transformacja tekstu przez BGE-M3 odbywa się w 24-warstwowym transformerze, który przetwarza tokeny uwzględniając kontekst, generując reprezentacje odpornie na szum informacyjny.

Komponenty wektorowe

- Wektory gęste: 1024 wymiary
- Wektory rzadkie: zależne od słownika
- Wektor pomocniczy: 1024 wymiary
- Każdy punkt w Qdrant: zbiór nazwanych wektorów

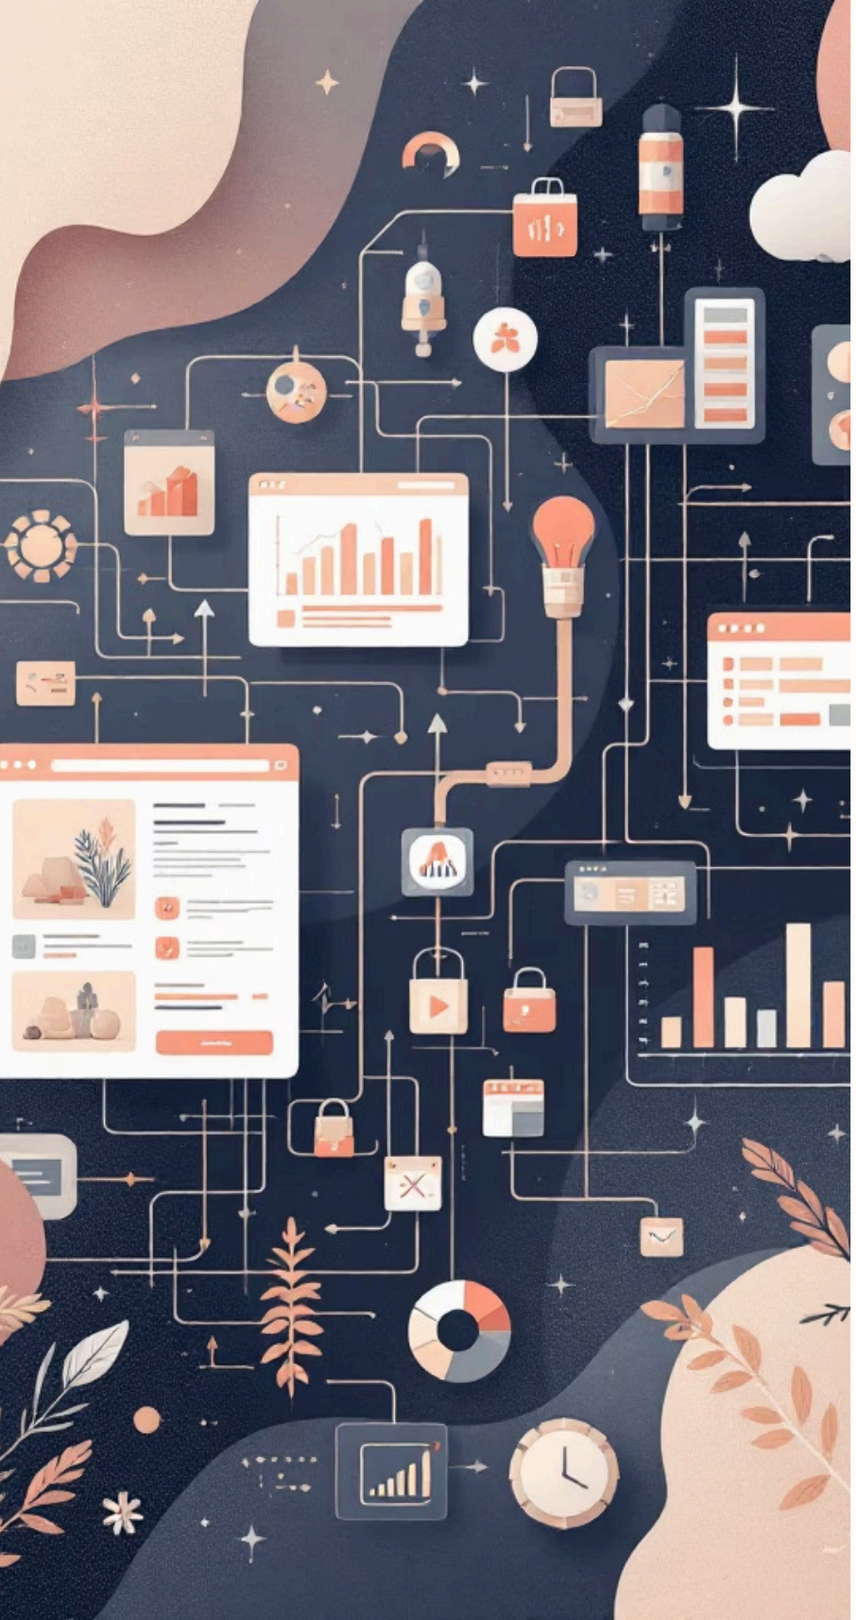

Inteligentny scraping: TME, TIM

Moduł scrape wykorzystuje asynchroniczną bibliotekę Playwright do symulacji przeglądarki Chromium, umożliwiając pobieranie danych ze stron dynamicznie renderowanych przez JavaScript.

01

Emulacja przeglądarki

Playwright symuluje zachowanie Chromium, rotuje rezydencjalne adresy IP i zarządza odciskami palców przeglądarki, unikając blokowania przez systemy ochrony (DataDome)

02

Ekstrakcja danych strukturalnych

Wykorzystanie JSON-LD i metatagów OpenGraph do pobierania ustandaryzowanych pól: cena, marka, kod EAN/GTIN

03

Parsowanie specyfikacji

Analiza tabel z parametrami technicznymi, automatyczne wypełnianie segmentów struktury indeksu (np. wyciągnięcie "M12" dla segmentu Cecha)

04

Przetwarzanie opisów

Przetwarzanie tekstu naturalnego w celu wzbogacenia kontekstu semantycznego dla modelu BGE-M3

Porównanie technik scrapingu: Playwright vs. BeautifulSoup

Wybór odpowiedniego narzędzia do scrapingu danych jest kluczowy dla efektywności i niezawodności systemu. Projekt IndeksyGSR wykorzystuje oba rozwiązania w zależności od specyfiki źródła danych.

Playwright: Dynamiczne strony i interakcje

Playwright emuluje pełną przeglądarkę (Chromium), umożliwiając renderowanie JavaScriptu i interakcje podobne do ludzkich (scroll, opóźnienia). Idealny dla stron takich jak Allegro, które intensywnie wykorzystują JS i mechanizmy antybotowe. Zapewnia pełny kontekst strony, ale jest wolniejszy (~10 prod/min) i zużywa więcej zasobów.

BeautifulSoup: Szybkie parsowanie statycznego HTML

BeautifulSoup, w połączeniu z httpx, jest biblioteką do szybkiego parsowania statycznego HTML. Nie uruchamia przeglądarki, co czyni go znacznie szybszym (~100-200 prod/min) i oszczędniejszym w zasobach. Doskonały do bulk-scrapingu zwykłych stron B2B z przeważnie statyczną zawartością, ale nie radzi sobie z treściami generowanymi przez JavaScript.

Kryterium	Playwright	BeautifulSoup + httpx
Szybkość	~10 prod/min (przeglądarka + slow_mo)	~100–200 prod/min (samo HTTP)
Zużycie RAM	Wysokie — pełna instancja Chromium	Minimalne — tylko HTTP + parse
Obsługa JavaScript	✅ Pełna — React, Angular, lazy-load	❌ Brak — dostaje tylko statyczny HTML
Dynamiczne treści	✅ Widzi wszystko po renderowaniu JS	❌ Nie widzi treści generowanych przez JS
Allegro / captcha	✅ Może kliknąć, scrollować, czekać	❌ Zablokowany przez bot detection
Open Graph / meta tagi	✅ (przez DOM lub parser)	✅ Działa doskonale (meta tagi w HTML)
Złożoność kodu	Wysoka — async, eventy, selektory DOM	Niska — prosty parse HTML
Problem Windows asyncio	⚠️ NotImplementedError w Streamlit	✅ Brak problemu — czyste HTTP
Równoległość	Słaba — 1 strona na raz w projekcie	✅ 10 równoległych requestów
Detekcja jako bot	Trudniejsza do wykrycia (prawdziwy browser)	Łatwiej wykrywalna (brak fingerprint)

Specjalny moduł do scrapingu Allegro

Allegro, kluczowa domena w projekcie, wymaga dedykowanego modułu ekstrakcji danych z uwagi na zaawansowany system antybotowy DataDome oraz niestandardową strukturę HTML.

01

Symulacja ludzkiego zachowania

Losowe opóźnienia i przewijanie strony, aby omijać zaawansowane systemy antybotowe DataDome.

02

Automatyczne omijanie CAPTCHA

Rozpoznawanie i automatyczne rozwiązywanie wizualnych wyzwań weryfikacyjnych.

03

Dynamiczne ładowanie treści

Czekanie na pełne renderowanie treści JavaScript i nagłówków produktu.

04

Ekstrakcja danych i specyfikacji

Odczyt ceny i parametrów technicznych z niestandardowych atrybutów HTML, wykorzystując wiele selektorów.

05

Inteligentne parsowanie opisów

Użycie modelu Groq LLM do weryfikacji i ekstrakcji właściwych opisów produktów, filtrując zbędne informacje.

Hybrydowe wyszukiwanie i i mechanizm Reciprocal Rank Fusion (RRF)

Wyszukiwanie w bazie Qdrant realizowane przez IndeksyGSR opiera się na wieloetapowym potoku, który wykorzystuje Universal Query API do łączenia sygnałów pochodzących z różnych typów wektorów w jednym spójnym procesie wyszukiwania.

Normalizacja

Standaryzacja kodów technicznych, np. „m12” → „M12”, oraz mapowanie synonimów materiałowych, np. „inox” → „stal nierdzewna A2”.

Prefetching

Równoległe pobieranie kandydatów z wektorów gęstych i rzadkich, przy czym każdy kanał zwraca niezależnie własną listę top-N wyników.

Fuzja RRF

Reciprocal Rank Fusion łączy listy rankingowe z wielu źródeł w jedną, wspólną kolejność, premiując dokumenty, które konsekwentnie pojawiają się wysoko we wszystkich wynikach cząstkowych.

Formuła matematyczna RRF

Wynik dokumentu d oblicza się jako sumę wkładów pochodzących z poszczególnych rankingów: dla każdego źródła uwzględniana jest jego waga w_i oraz pozycja dokumentu $rank_i(d)$ w danym rankingu, a parametr k pełni rolę stałej wygładzającej i ogranicza przewagę najwyżej ocenionych pozycji (domyślnie 60).

$$score(d) = \sum_i \frac{w_i}{k + rank_i(d)}$$

Im wyżej dokument znajduje się w kolejnych źródłach, tym większy otrzymuje łączny score. Dzięki temu RRF wzmacnia wyniki stabilnie silne w wielu sygnałach jednocześnie, zamiast faworyzować pojedynczy, przypadkowo dobry ranking.

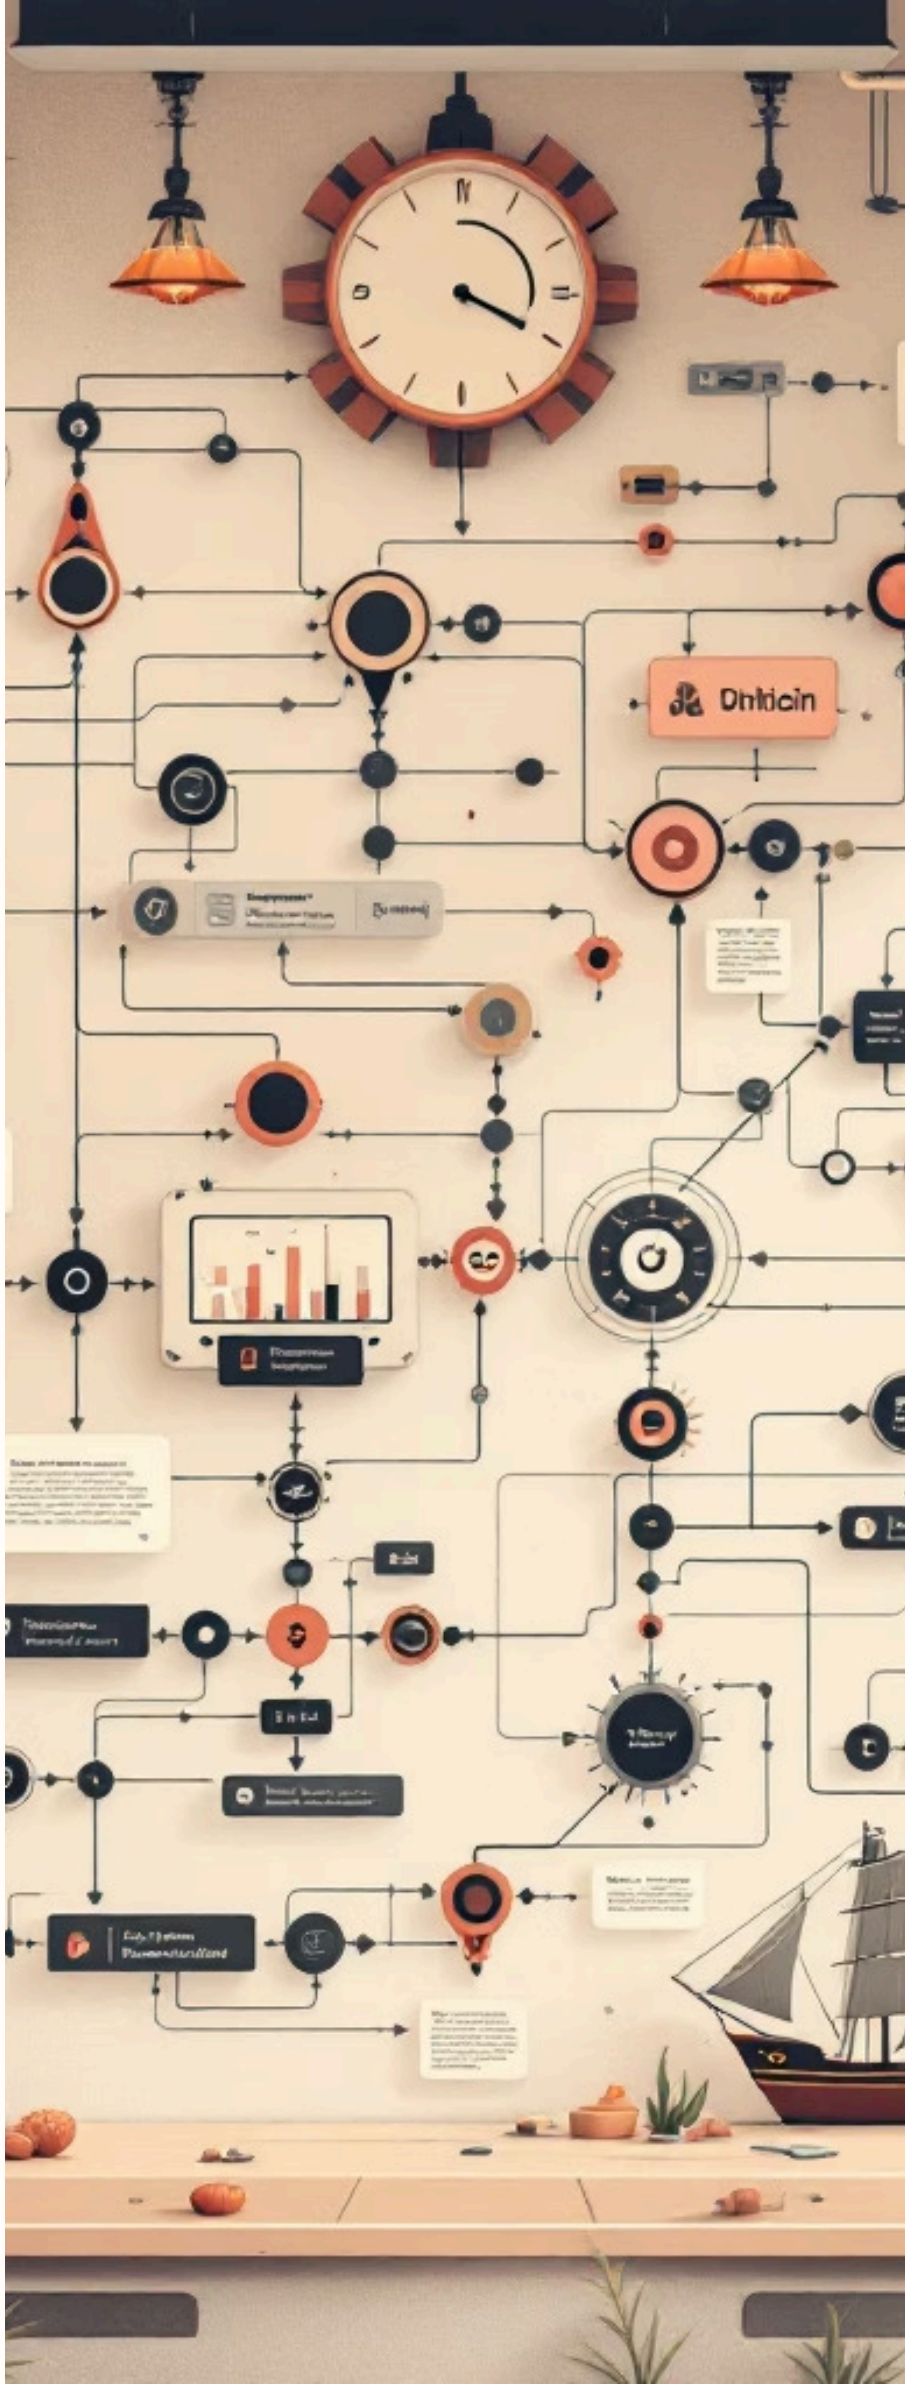

Wagowanie segmentów i Score-Boosting

Siedmiosegmentowa struktura indeksu jest przechowywana w payloadzie punktów Qdrant jako ustrukturyzowany obiekt JSON. System wykorzystuje te metadane do aktywnego wpływania na wynik wyszukiwania poprzez mechanizm Score-Boosting Reranker.

Typ (1.0)

Kategoria nadrzędna (np. Śruba) - krytyczna dla identyfikacji

Cecha (0.95)

Kluczowe parametry (np. średnica, skok)

Grupa (0.9)

Norma lub standard (np. DIN 933)

Materiał (0.85)

Skład i wytrzymałość (np. 8.8, inox)

Podgrupa (0.7)

Wariant wykonania

Odbiór (0.5)

Certyfikacja jakościowa

Numer (0.3)

Unikalny identyfikator porządkowy

Wagi odzwierciedlają znaczenie segmentów w procesie identyfikacji materiału. Jeśli zapytanie sugeruje konkretną grupę (np. "DIN 931"), punkty z tą wartością w payloadzie otrzymują premię do wyniku końcowego.

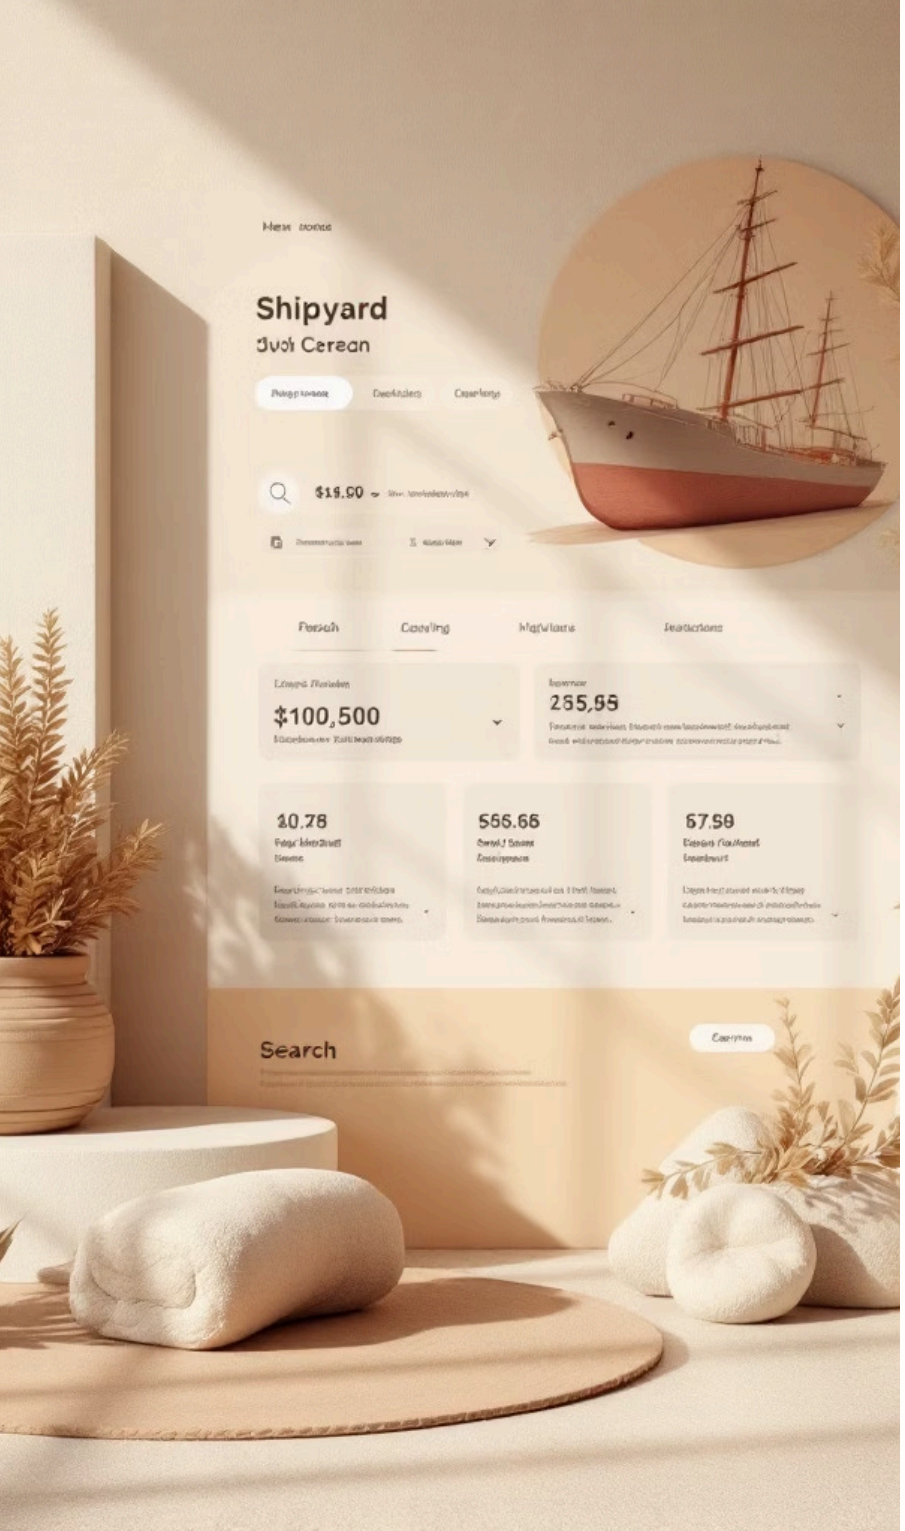

Reranking Cross-Encoderem i prezentacja wyników

Dwuetapowy proces rerankingu

Mimo zaawansowanej fuzji RRF, modele Bi-Encoder mają ograniczenia w rozróżnianiu bardzo zbliżonych parametrów numerycznych. IndeksyGSR wprowadza drugi etap rerankingu przy użyciu modelu Cross-Encoder bge-reranker-v2-m3.

Cross-Encoder analizuje zapytanie i dokument jednocześnie, uwzględniając interakcje między słowami i liczbami na poziomie tokenów. Proces stosowany tylko do 50 najlepszych kandydatów z fazy hybrydowej.

Interfejs Streamlit

- Widok e-maili i produktów
- Wyszukiwarka semantyczna
- Panel propozycji
- Karty z metadanymi i snippetami

Moduł suggest

Gdy zapytanie nie pasuje do istniejącego indeksu, system wykorzystuje LLM do analizy danych technicznych i dekompozycji na siedem segmentów struktury organizacyjnej.

Wnioski: skok cywilizacyjny w zarządzaniu danymi

Wdrożenie systemu IndeksyGSR opartego na modelu BGE-M3 i bazie Qdrant stanowi przejście od statycznego wyszukiwania po kodach do dynamicznej, wielowektorowej analizy semantycznej.

Eliminacja duplikatów

System identyfikuje produkty po istocie technicznej, blokując wprowadzanie powtarzających się rekordów

Automatyzacja ingestii

Scraping serwisów zdejmuje ciężar ręcznego przepisywania specyfikacji, redukując błędy

Wsparcie decyzyjne

Moduł sugestii LLM dba o spójność siedmiosegmentowej logiki organizacji

Dalszy rozwój

System powinien skupić się na rozszerzeniu pętli zwrotnej o mechanizmy aktywnego uczenia, gdzie najbardziej niejednoznaczne przypadki są automatycznie kierowane do ekspertów dziedzinowych. Organizacja zyskuje narzędzie, które nie tylko rozwiązuje bieżące problemy z duplikatami, ale staje się żywą bazą wiedzy technicznej, ewoluującą wraz z rynkiem i potrzebami produkcyjnymi.