Optymalizacja zarządzania indeksami materiałowymi z bazami wektorowymi

Wdrożenie systemu IndeksyGSR opartego na architekturze Qdrant i modelu BGE-M3

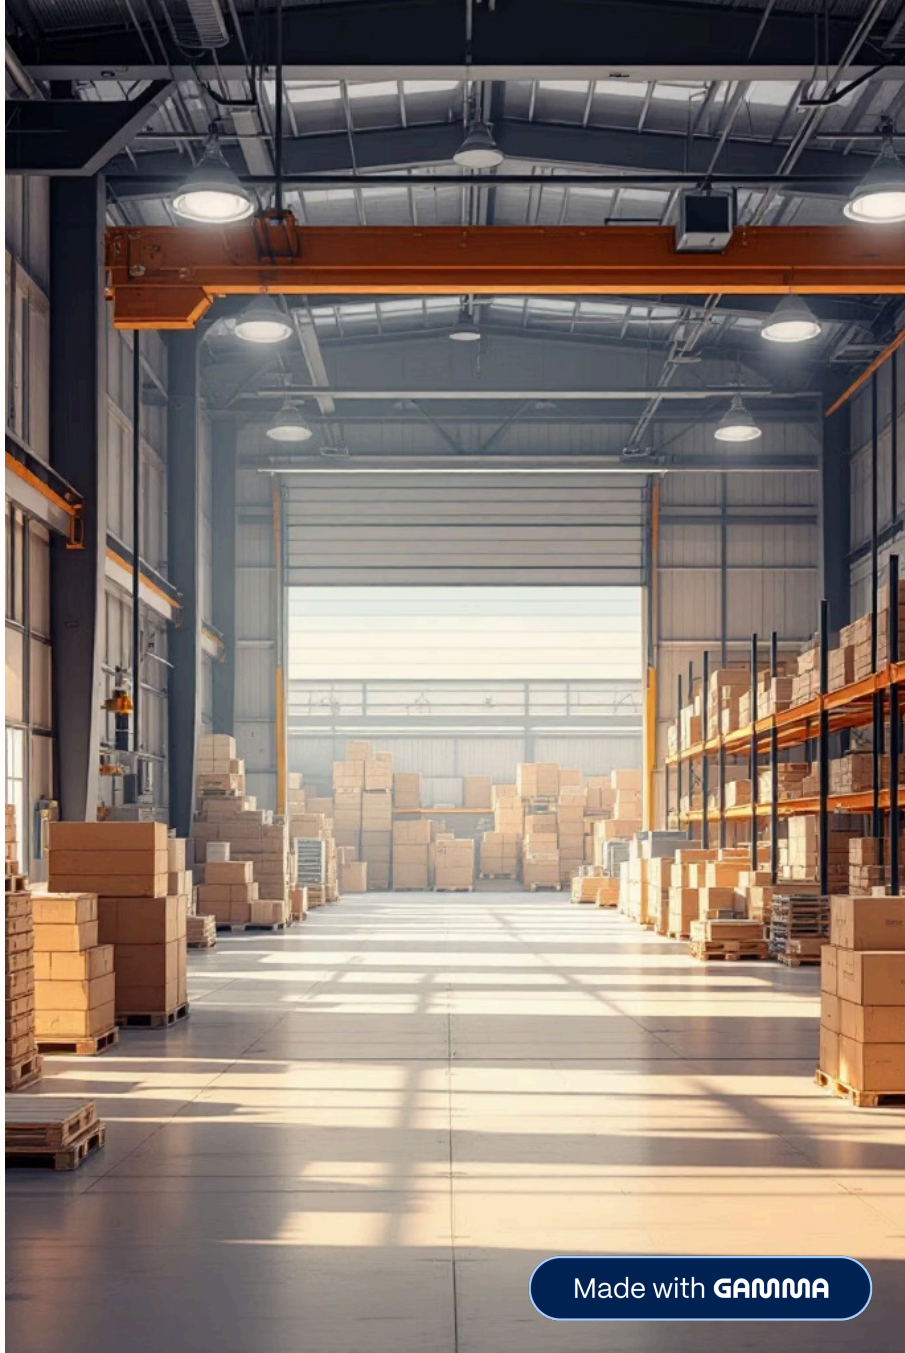

Made with GAMMA

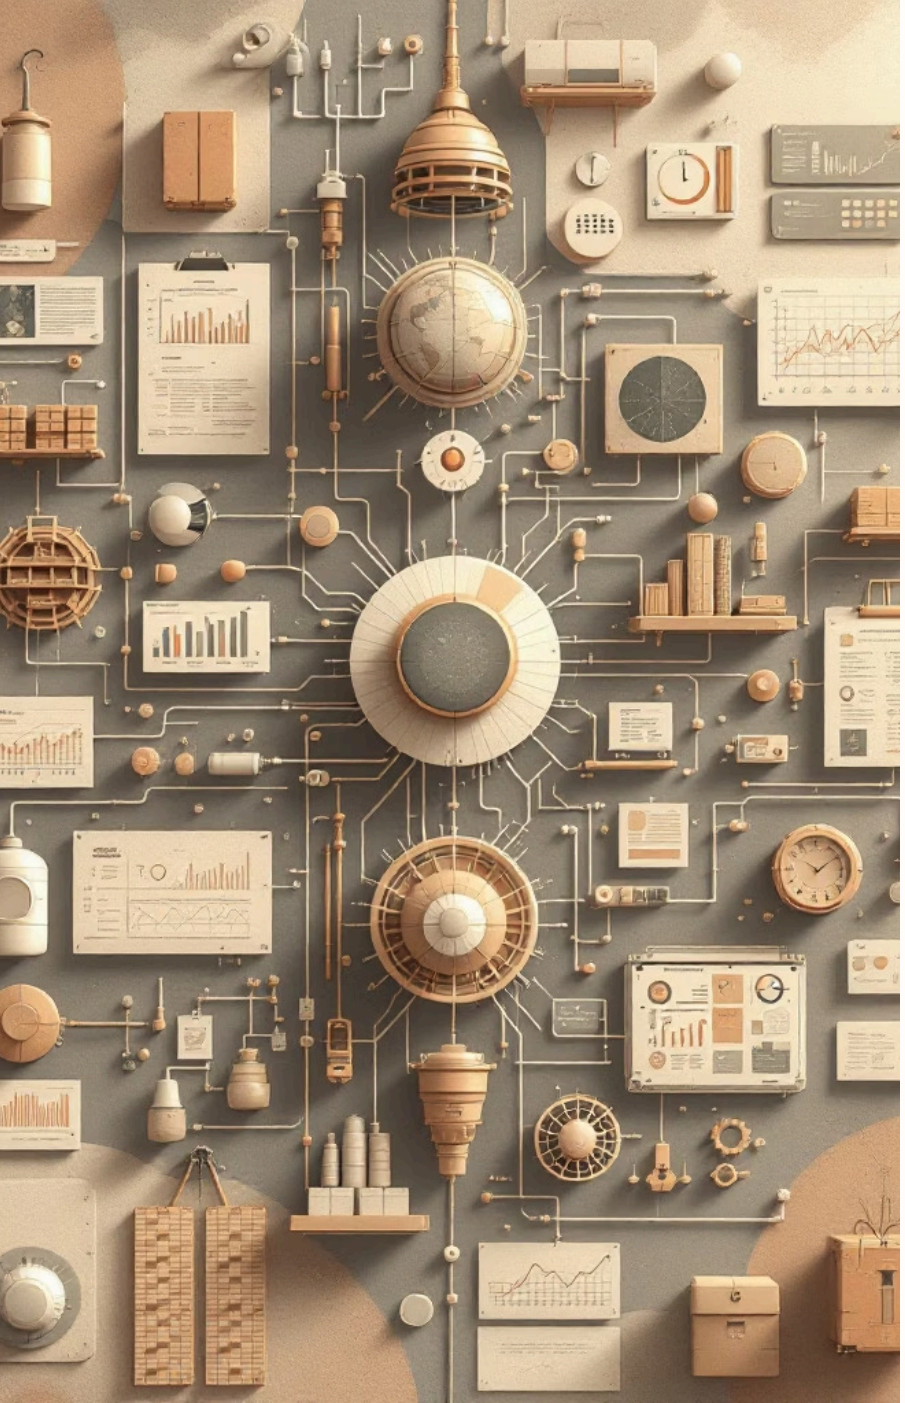

Problem złożonych struktur indeksowania

Kontekst operacyjny

W dużych organizacjach produkcyjnych i logistycznych, zarządzanie złożonymi strukturami indeksowania stanowi kluczowe wyzwanie w utrzymaniu spójności danych operacyjnych. Analizowana organizacja operuje na siedmiosegmentowej strukturze indeksu, obejmującej: Typ, Grupę, Podgrupę, Cechę, Materiał, Odbiór oraz Numer kolejny.

Taka granulacja, choć teoretycznie pozwalająca na precyzyjną identyfikację zasobów, w praktyce staje się źródłem redundancji i błędów wynikających z czynnika ludzkiego. Proces wprowadzania danych jest podatny na nieścisłości terminologiczne, co prowadzi do powstawania duplikatów i paraliżuje efektywność łańcucha dostaw.

Skala problemu

~69 000 zindeksowanych materiałów w organizacji, wymagających ciągłej aktualizacji i utrzymania spójności nomenklatury

Made with GAMMA

Architektura systemu IndeksyGSR

System został zaprojektowany jako kompleksowe rozwiązanie typu pipeline, integrujące rozproszone źródła danych od lokalnych plików po zasoby chmurowe i serwisy e-commerce.

Backend core

Logika wyszukiwania i sugestii, hybrydowe wyszukiwanie semantyczne z RRF, automatyczne sugestie dla nowych indeksów

Pipeline przetwarzania

Parsowanie wiadomości e-mail (.pst), asynchroniczny scraping danych z serwisów Allegro, TME, TIM

Warstwa usług

Komunikacja z bazami Firestore i Qdrant Cloud, embed-server oparty na FastAPI

Made with GAMMA

Model BGE-M3: trzy typy reprezentacji

Wybór modelu BAAI/bge-m3 jako silnika wektoryzacji jest podyktowany jego unikalną zdolnością do obsługi trzech typów reprezentacji w jednym przebiegu, co jest niezwykle istotne w kontekście technicznych indeksów materiałowych.

Wektory gęste (Dense)

1024-wymiarowe reprezentacje uchwytyujące głębokie znaczenie zapytania. System rozumie, że "inox" jest semantycznie tożsamy z "A2" lub "stal nierdzewna", nawet jeśli te słowa nie występują bezpośrednio.

Wektory rzadkie (Sparse)

Oparte na wagach SPLADE, realizują wyszukiwanie leksykalne, skuteczne przy dopasowywaniu specyficznych kodów technicznych jak "M20" czy "DIN 933".

Wektory pomocnicze (Auxiliary)

1024-wymiarowe, dedykowane wyszukiwaniu po surowej nazwie indeksu, umożliwiające szybkie dopasowanie identyfikatorów i nazw własnych.

Made with GAMMA

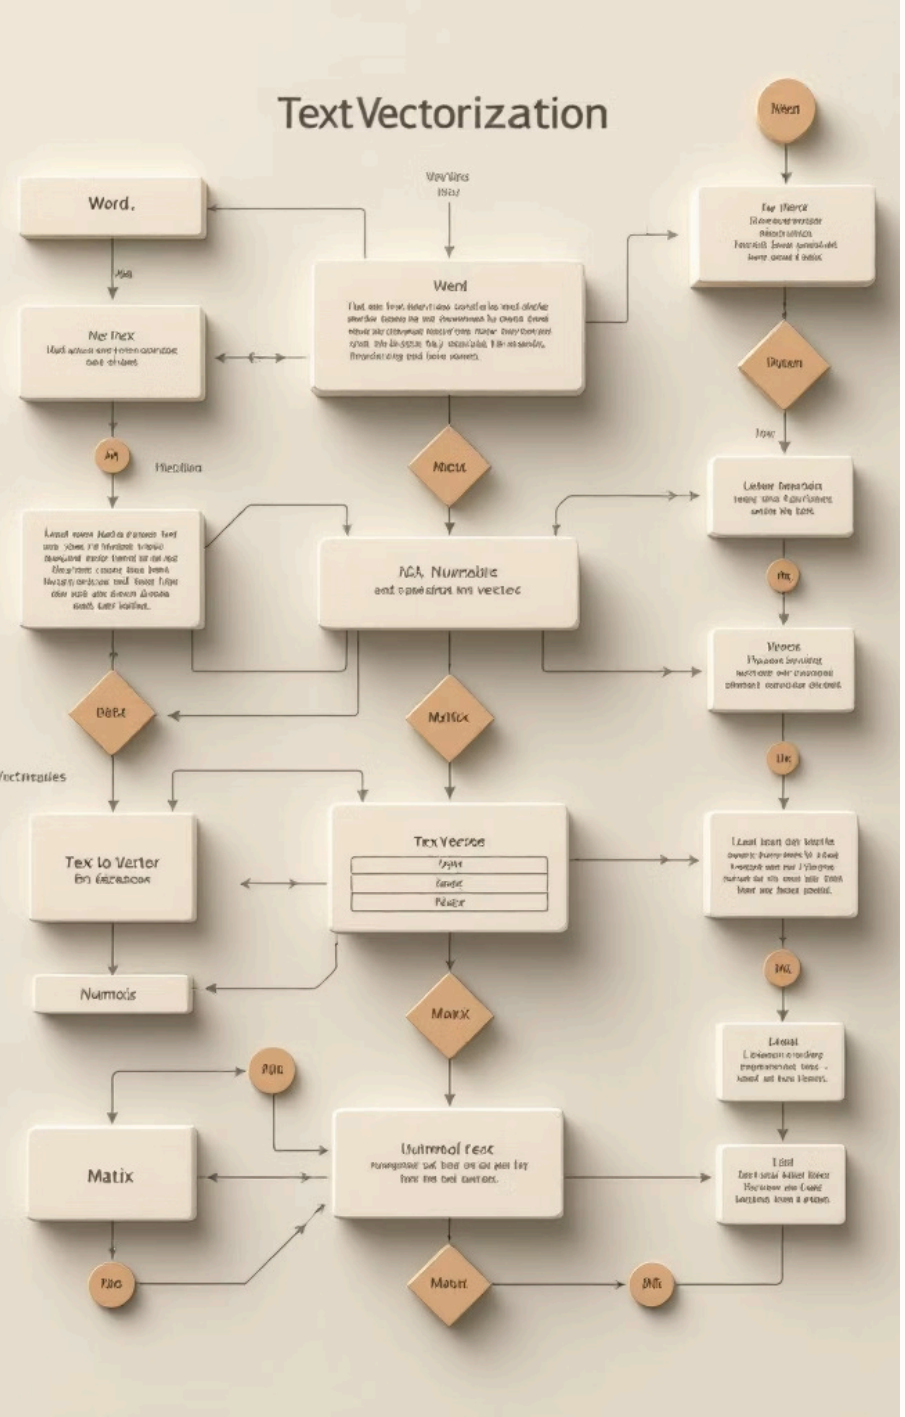

Proces wektoryzacji danych

Trzywarstwowa transformacja tekstu

Proces budowania tekstu do wektoryzacji jest wielowarstwowy i obejmuje:

1. Trzy poziomy segmentów asortymentowych (Typ, Grupa, Podgrupa)
2. Pełną nazwę indeksu
3. Dane uzupełniające: tytuły i specyfikacje techniczne pozyskane drogą scrapingu

Transformacja tekstu przez BGE-M3 odbywa się w 24-warstwowym transformerze, który przetwarza tokeny uwzględniając kontekst, generując reprezentacje odpornie na szum informacyjny.

Komponenty wektorowe

- Wektory gęste: 1024 wymiary
- Wektory rzadkie: zależne od słownika
- Wektor pomocniczy: 1024 wymiary
- Każdy punkt w Qdrant: zbiór nazwanych wektorów

Made with GAMMA

Inteligentny scraping: Allegro, TME, TIM

Moduł scrape wykorzystuje asynchroniczną bibliotekę Playwright do symulacji przeglądarki Chromium, umożliwiając pobieranie danych ze stron dynamicznie renderowanych przez JavaScript.

01

Emulacja przeglądarki

Playwright symuluje zachowanie Chromium, rotuje rezydencjalne adresy IP i zarządza odciskami palców przeglądarki, unikając blokowania przez systemy ochrony (DataDome)

02

Ekstrakcja danych strukturalnych

Wykorzystanie JSON-LD i metatagów OpenGraph do pobierania ustandaryzowanych pól: cena, marka, kod EAN/GTIN

03

Parsowanie specyfikacji

Analiza tabel z parametrami technicznymi, automatyczne wypełnianie segmentów struktury indeksu (np. wyciągnięcie "M12" dla segmentu Cecha)

04

Przetwarzanie opisów

Przetwarzanie tekstu naturalnego w celu wzbogacenia kontekstu semantycznego dla modelu BGE-M3

Made with GAMMA

Hybrydowe wyszukiwanie i fuzja RRF

Wyszukiwanie w bazie Qdrant realizowane przez IndeksyGSR jest wieloetapowym potokiem wykorzystującym Universal Query API do łączenia sygnałów z różnych typów wektorów.

Normalizacja

Ujednolicanie kodów technicznych i mapowanie synonimów materiałowych

Prefetching

Równoległe pobieranie kandydatów z wektorów gęstych i rzadkich

Fuzja RRF

Łączenie wyników z Reciprocal Rank Fusion

Formuła matematyczna RRF

Wynik dokumentu d określa się jako sumę odwrotności rang z poszczególnych źródeł:

$$score(d) = \sum_i \frac{w_i}{k + rank_i(d)}$$

gdzie w_i to waga danego rankingu, a k to stała wygładzająca (domyślnie 60)

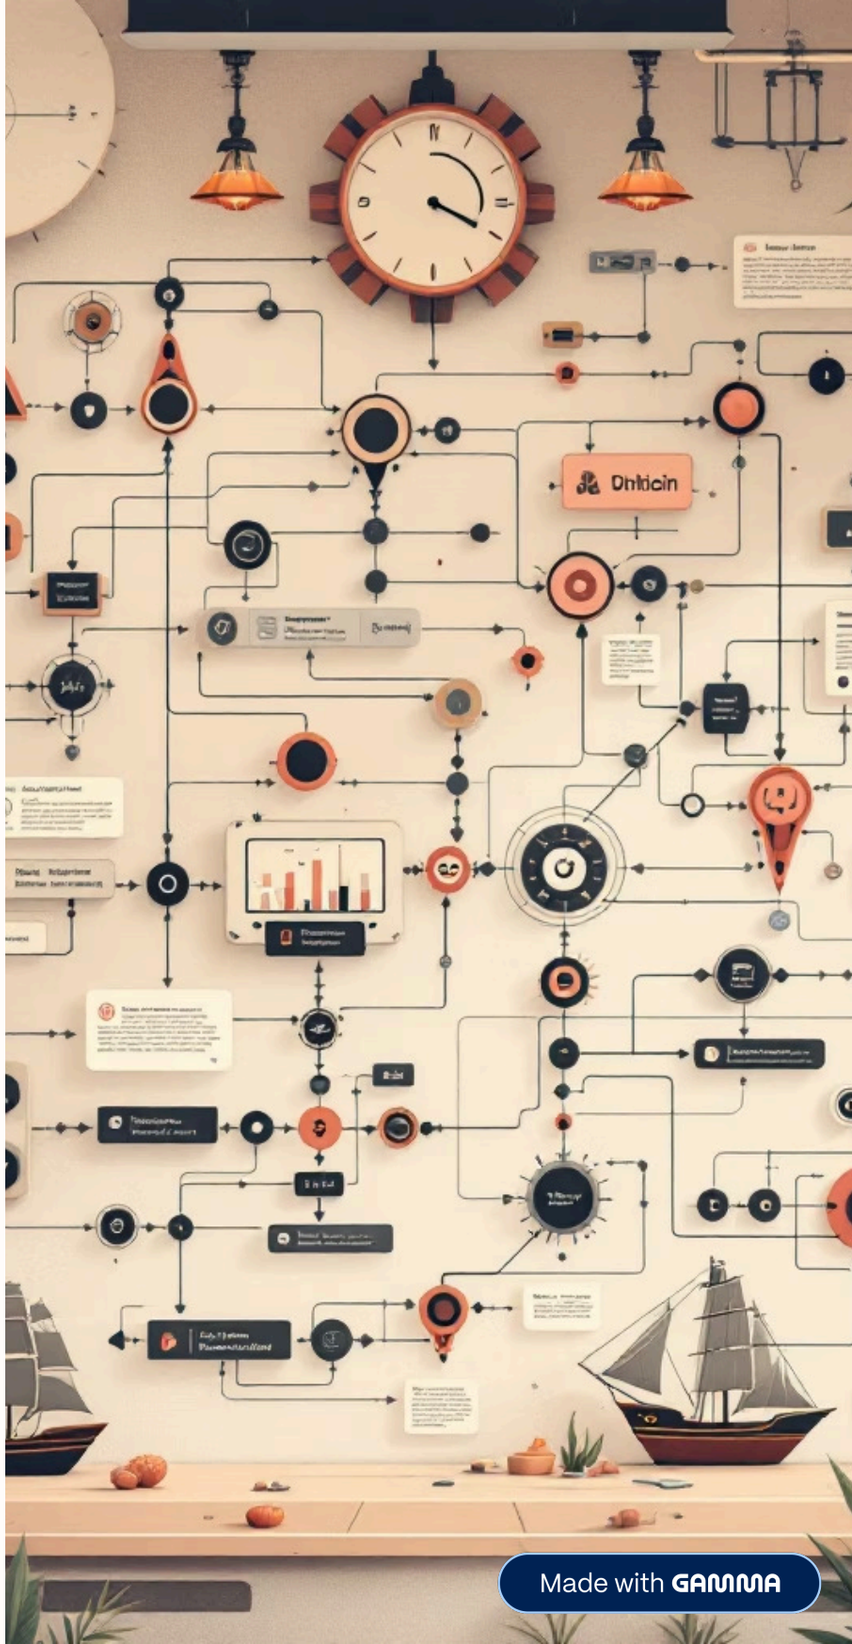

Made with GAMMA

Wagowanie segmentów i Score-Boosting

Siedmiosegmentowa struktura indeksu jest przechowywana w payloadzie punktów Qdrant jako ustrukturyzowany obiekt JSON. System wykorzystuje te metadane do aktywnego wpływania na wynik wyszukiwania poprzez mechanizm Score-Boosting Reranker.

Typ (1.0)

Kategoria nadrzędna (np. Śruba) - krytyczna dla identyfikacji

Cecha (0.95)

Kluczowe parametry (np. średnica, skok)

Grupa (0.9)

Norma lub standard (np. DIN 933)

Materiał (0.85)

Skład i wytrzymałość (np. 8.8, inox)

Podgrupa (0.7)

Wariant wykonania

Odbiór (0.5)

Certyfikacja jakościowa

Numer (0.3)

Unikalny identyfikator porządkowy

Wagi odzwierciedlają znaczenie segmentów w procesie identyfikacji materiału. Jeśli zapytanie sugeruje konkretną grupę (np. "DIN 931"), punkty z tą wartością w payloadzie otrzymują premię do wyniku końcowego.

Made with GAMMA

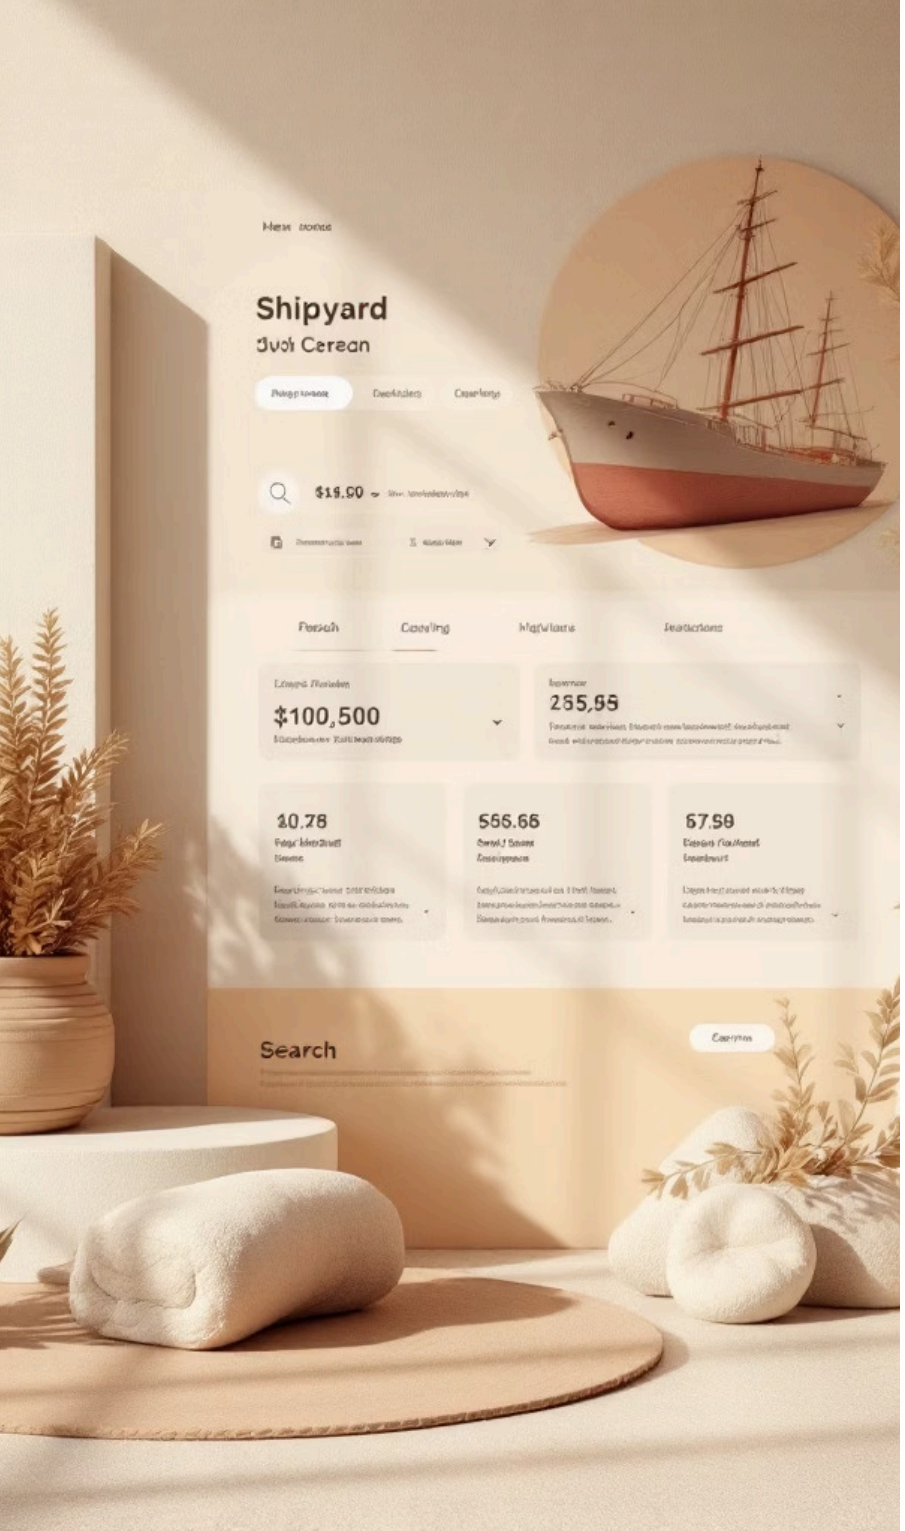

Reranking Cross-Encoderem i prezentacja wyników

Dwuetapowy proces rerankingu

Mimo zaawansowanej fuzji RRF, modele Bi-Encoder mają ograniczenia w rozróżnianiu bardzo zbliżonych parametrów numerycznych. IndeksyGSR wprowadza drugi etap rerankingu przy użyciu modelu Cross-Encoder bge-reranker-v2-m3.

Cross-Encoder analizuje zapytanie i dokument jednocześnie, uwzględniając interakcje między słowami i liczbami na poziomie tokenów. Proces stosowany tylko do 50 najlepszych kandydatów z fazy hybrydowej.

Interfejs Streamlit

- Widok e-maili i produktów
- Wyszukiwarka semantyczna
- Panel propozycji
- Karty z metadanymi i snippetami

Moduł suggest

Gdy zapytanie nie pasuje do istniejącego indeksu, system wykorzystuje LLM do analizy danych technicznych i dekompozycji na siedem segmentów struktury organizacyjnej.

Made with GAMMA

Wnioski: skok cywilizacyjny w zarządzaniu danymi

Wdrożenie systemu IndeksyGSR opartego na modelu BGE-M3 i bazie Qdrant stanowi przejście od statycznego wyszukiwania po kodach do dynamicznej, wielowektorowej analizy semantycznej.

Eliminacja duplikatów

System identyfikuje produkty po istocie technicznej, blokując wprowadzanie powtarzających się rekordów

Automatyzacja ingestii

Scraping serwisów zdejmuje ciężar ręcznego przepisywania specyfikacji, redukując błędy

Wsparcie decyzyjne

Moduł sugestii LLM dba o spójność siedmiosegmentowej logiki organizacji

Dalszy rozwój

System powinien skupić się na rozszerzeniu pętli zwrotnej o mechanizmy aktywnego uczenia, gdzie najbardziej niejednoznaczne przypadki są automatycznie kierowane do ekspertów dziedzinowych. Organizacja zyskuje narzędzie, które nie tylko rozwiązuje bieżące problemy z duplikatami, ale staje się żywą bazą wiedzy technicznej, ewoluującą wraz z rynkiem i potrzebami produkcyjnymi.

Made with GAMMA